测量应如何进入流匹配 ODE 采样?
稀疏视角与低剂量 CT 的对照研究

张伟豪
河北大学
20268018055@stumail.hbu.edu.cn

摘要

流匹配先验越来越多地用于 CT 重建，但已发表的方法往往同时改变了先验、网络、数据和测量注入规则，因而很难判断究竟是哪一项在起作用。本文固定其他一切，只改变测量注入规则。在同一个基于公开 TotalSegmentator CT 数据（1228 例，官方按病人划分）训练的 19.8M 参数 rectified flow 先验上，我们在同一个 Euler ODE 积分器内比较三种规则：梯度引导（DPS 式）、伪逆引导（ΠGDM 式）和近端数据一致性（DDS/DDNM 式），并与 FBP 以及同骨干的监督网络 FBPConvNet 对比，覆盖 30/60/90 视角稀疏采样与低剂量平行束 CT。引导强度采用与步数、视角数无关的单位，只在验证集病人上选取；所有比较都给出按病人聚类的 bootstrap 置信区间。主要发现有三点：(i) 60 视角下伪逆引导的单样本最好（36.9 dB，比 FBPConvNet 高 1.4 dB，95% CI $[0.95, 1.91]$）；近端一致性步数效率最高（20 步即达 36.2 dB），后验均值也最好（8 个样本时比 FBPConvNet 高 3.9 dB）。(ii) DPS 式梯度引导在流 ODE 上失效：无论视角数多少都饱和在约 24.5 dB，并会产生解剖结构幻觉；初步测量显示其梯度沿轨迹变化约 60 倍。(iii) 存在光子噪声且没有显式噪声模型时，监督基线仍然更好（$I_0{=}10^5$ 时高 2.2 dB）；把 $I_0{=}10^5$ 上选出的强度直接（不重新调参）用于 $I_0{=}10^4$ 时，排名发生倒转。代码、配置与逐图结果已公开。

1 引言

生成式先验已成为病态 CT 重建中监督后处理之外的有力选择：同一个无条件先验可以复用于不同采集协议，后验采样还能暴露确定性网络所隐藏的不确定性 [1–3]。这方面的工作大多基于扩散 SDE。流匹配与 rectified flow [4, 5] 则学习一个速度场，其 ODE 沿近似直线的路径把噪声输运到数据。这使少步采样很有吸引力，但也改变了测量信息*应在何处、以多大强度*注入：ODE 没有逐步重新加噪的过程来吸收引导误差。

流先验用于 CT 是当前的活跃方向 [6–9]，通用流求解器也以多种方式改造了扩散引导 [10–12]。这些研究大多在改变引导规则的同时也改变了先验、网络、数据或步长调度；Evangelista [6] 确实在同一先验（Mayo LDCT）上比较了多个流求解器，但没有采用与步数和视角数无关的引导强度单位，没有仅用验证集调参，也没有给出按病人的置信区间。引导权重通常依经验选取，而近期工作表明这一选择往往起决定作用 [13, 14]。因此本文只隔离*测量如何进入 ODE* 这一个因素。在

TotalSegmentator CT [15] 上训练的同一个流匹配先验上，我们比较：(M1) 穿过网络的 DPS 式梯度步 [3]；(M2) ΠGDM 式伪逆修正 [16]；(M3) 对预测干净图做共轭梯度近端投影 [17]。三者共享先验、积分器、网络函数评估次数（NFE）、基于验证集的调参协议和测试集，并与 FBP 以及同骨干的监督 FBPConvNet [18] 对比。

贡献。

- 在公开数据上、共享 rectified flow 先验的条件下，对稀疏视角（30/60/90）与低剂量 CT 的三种测量注入规则做对照比较，仅用验证集调参，并给出按病人的 bootstrap 区间（表 1、表 2）。
- 使引导强度在不同 NFE、不同视角数之间可比的单位约定：DPS 步长乘以 Δt 并除以 $\sqrt{s_x}$，近端权重以 s_x 为单位（$s_x = \mathrm{tr}(\mathcal{A}^\top \mathcal{A})/N^2$，见第 3.3 节）；否则 NFE 消融与跨协议比较会被混淆。
- 证据表明梯度引导在流 ODE 上无法利用更多视角（结果不随视角数变化，并有初步测量显示引导梯度沿轨迹变化约 60 倍）；伪逆规则与近端规则的不确定性表现不同，使二者在单样本和后验均值上的排名相反。

2 相关工作

扩散后验采样。 DPS [3] 和 MCG [2] 把测量损失穿过去噪网络反传；ΠGDM [16] 在 $p(\boldsymbol{x}_0 \mid \boldsymbol{x}_t)$ 的高斯近似下用伪逆修正代替梯度；DiffPIR [19]、DDS [17] 和 DAPS [20] 在去噪与近端 / 数据一致性步之间交替；RED-diff [21] 把采样视为变分优化。针对 CT，基于分数的先验 [1]、DiffusionMBIR [22]、DiffusionBlend [23] 和 DOLCE [24] 分别处理稀疏视角、三维与限角问题。DM4CT [7] 对十种扩散方法做了 CT 基准测试；本文与之互补：固定一个流先验，只改变注入规则。

流先验用于反问题与 CT。 OT-ODE [10] 为条件 OT 路径推导了类 ΠGDM 修正；PnP-Flow [11] 在流去噪与即插即用投影之间交替；FlowDPS [12] 把流更新分解为干净图与噪声两部分。CT 方面，Evangelista [6] 在 Mayo LDCT 上训练 rectified flow 先验，并与扩散基线比较了多个流求解器；EFMCT [8] 在数据一致性中跨步复用速度场；LUCID [9] 按稀疏程度调整轨迹并在投影域做修正。引导权重的选取近期有离线最小二乘 [13] 和学习式调度 [14, 25] 两类方法。本文的范围不同：单一先验、三种注入规则、与步数和视角无关的单位、公开数据上仅用验证集调参，以及按病人的统计。

监督 CT 重建。 FBPConvNet [18] 与 LEARN [26] 学习从欠采样数据到图像的映射；它们在分布内很强，但每个协议都要重训。

3 方法

3.1 成像模型

轴位切片 $\boldsymbol{x} \in [-1,1]^{N\times N}$（$N$=256，HU 窗 $[-1000, 1000]$）映射为衰减 $u = m \odot (\boldsymbol{x}+1)/2$，$m$ 为内切圆掩码。平行束投影 R_Θ 在 $[0,\pi)$ 内取 $|\Theta|$ 个等距角度；前向模型对 $\boldsymbol{x}$ 是仿射的：

$$\mathcal{A}(\boldsymbol{x}) = R_\Theta(u) = \mathcal{A}_{\text{lin}}\boldsymbol{x} + \boldsymbol{b}, \qquad \mathcal{A}_{\text{lin}}\boldsymbol{x} = R_\Theta(m \odot \boldsymbol{x}/2), \quad \boldsymbol{b} = R_\Theta(m/2). \tag{1}$$

R_Θ 用双线性插值旋转后求和实现，精确伴随由自动微分得到（伴随相对误差 $< 10^{-4}$，有单元测试）。稀疏视角取 $|\Theta| \in \{30, 60, 90\}$（全采样为 180）。低剂量取 180 视角，加 Poisson 计数噪声 $I \sim \text{Poisson}(I_0 e^{-\mu y})$，$\boldsymbol{y} = -\log(I/I_0)/\mu$，$\mu$=0.06；主设置为 I_0=10^5，I_0=10^4 作为光子饥饿的极端情形。第 i 张测试图的测量噪声由以 (seed, i) 为种子的生成器产生，因此无论 batch 大小、NFE 或后验采样次数如何，所有方法看到的 $\boldsymbol{y}$ 完全相同。

3.2 流匹配先验

令 $\boldsymbol{x}_t = (1-t)\boldsymbol{\epsilon} + t\boldsymbol{x}$，$\boldsymbol{\epsilon} \sim \mathcal{N}(0, I)$，速度网络最小化 $\mathbb{E}\|\boldsymbol{v}_\theta(\boldsymbol{x}_t, t) - (\boldsymbol{x} - \boldsymbol{\epsilon})\|^2$，$t$ 服从 logit-normal 分布 [27]。由任意状态可读出干净图与噪声的预测

$$\hat{\boldsymbol{x}}_1 = \boldsymbol{x}_t + (1-t)\,\boldsymbol{v}_\theta(\boldsymbol{x}_t, t), \qquad \hat{\boldsymbol{\epsilon}} = \boldsymbol{x}_t - t\,\boldsymbol{v}_\theta(\boldsymbol{x}_t, t). \tag{2}$$

无引导采样用步长 $\Delta t = 1/\text{NFE}$ 的 Euler 法把 $\dot{\boldsymbol{x}} = \boldsymbol{v}_\theta$ 从 t=0 积分到 1。

3.3 三种测量注入规则

所有规则都修改同一个 Euler 更新 $\boldsymbol{x} \leftarrow \boldsymbol{x} + \Delta t\,\boldsymbol{v}_\theta$。记 $\boldsymbol{r} = \boldsymbol{y} - \mathcal{A}(\hat{\boldsymbol{x}}_1)$，$s_x = \text{tr}(\mathcal{A}_{\text{lin}}^\top \mathcal{A}_{\text{lin}})/N^2$，$s_y = \text{tr}(\mathcal{A}_{\text{lin}} \mathcal{A}_{\text{lin}}^\top)/M$（$M$ 为测量数），二者对每个算子用 16 个高斯探针估计一次。

M1：梯度引导（DPS 式）。

$$\boldsymbol{x}_{t+\Delta t} = \boldsymbol{x}_t + \Delta t \left(\boldsymbol{v}_\theta - \frac{\zeta}{\sqrt{s_x}} \nabla_{\boldsymbol{x}_t} \|\mathcal{A}(\hat{\boldsymbol{x}}_1) - \boldsymbol{y}\|_2 \right) \quad (t \geq t_s). \tag{3}$$

与 DPS 一致，使用残差范数的梯度。与常见实现不同，引导乘以 Δt，使积分后的总引导量与 NFE 无关（否则 NFE 消融会悄悄改变 ζ 的实际大小）；并除以 $\sqrt{s_x}$，使 ζ 在不同视角数下可比。由于梯度范数沿轨迹变化很大（见第 5 节” 梯度引导为何失效”），我们额外调节引导起始时刻 t_s。

M2：伪逆引导（ΠGDM 式）。 在 $\hat{\boldsymbol{x}}_1 \mid \boldsymbol{x}_t \sim \mathcal{N}(\hat{\boldsymbol{x}}_1, r_t^2 I)$、$r_t^2 = (1-t)^2/(t^2 + (1-t)^2)$（ΠGDM 方差在流上的对应）的假设下，在测量空间用 K=5 次共轭梯度迭代求解

$$\left(\mathcal{A}_{\text{lin}} \mathcal{A}_{\text{lin}}^\top + (\sigma_y^2/r_t^2 + \eta\, s_y) I\right) \boldsymbol{z} = \boldsymbol{r}, \tag{4}$$

其中 η=10^{-3}、σ_y=0，再穿过网络做向量–雅可比积：

$$\boldsymbol{x}_{t+\Delta t} = \boldsymbol{x}_t + \Delta t\, \boldsymbol{v}_\theta + \zeta\, t_+ \left(\frac{\partial \hat{\boldsymbol{x}}_1}{\partial \boldsymbol{x}_t}\right)^{\top} \mathcal{A}_{\text{lin}}^{\top} \boldsymbol{z}, \tag{5}$$

其中 $t_+ = t + \Delta t$ 对应 ΠGDM 中的信号系数 $\sqrt{\bar{\alpha}_t}$。

M3：近端数据一致性（DDS/DDNM 式）。 把预测干净图替换为

$$\hat{\boldsymbol{x}}_1^{\text{dc}} = \arg\min_{\boldsymbol{x}} \|\mathcal{A}(\boldsymbol{x}) - \boldsymbol{y}\|_2^2 + \lambda \|\boldsymbol{x} - \hat{\boldsymbol{x}}_1\|_2^2, \qquad \lambda = \tilde{\lambda}\, s_x, \tag{6}$$

用 K=5 次 CG 求解，再重组状态 $\boldsymbol{x}_{t+\Delta t} = (1 - t_+)\hat{\boldsymbol{\epsilon}} + t_+ \hat{\boldsymbol{x}}_1^{\text{dc}}$。M3 不需要穿过网络反传。

4 实验设置

数据。 TotalSegmentator v2.0.1 [15]（1228 例 CT，1.5 mm 各向同性），取自 Hugging Face 上 CC-BY-4.0 协议的重新打包版本（`YongchengYAO/TotalSegmentator-CT-Lite`，压缩包已对照其公布的 SHA-256 校验），采用官方按病人划分。每例最多沿 z 均匀取 40 张身体占比超过 10% 的轴位切片，中心裁剪到 256^2：训练 43,220 张（1082 位病人），验证 2,280 张（57 位），测试 3,560 张（89 位）。固定测试集 *test200* 为 20 位测试病人 × 10 张。引导强度只在均匀分布于验证病人的 50 张验证切片上选取，从不使用测试数据。

先验与基线。 先验为 19.8M 参数的 U-Net（基础宽度 64，通道倍数 1、1、2、2、4，每层两个残差块，16^2 处自注意力），训练 12 万步，batch 32，AdamW（学习率 2×10^{-4}，1k 步预热，余弦衰减到 10^{-5}），EMA 0.9995，bf16 自动混合精度。FBPConvNet 使用相同骨干（$t\equiv0$），在 FBP 结果上预测残差，每个协议单独训练 1 万步（batch 16，余弦调度），约 3.7 个 epoch，而先验约 89 个 epoch，因此其数字应视为下界。FBP 使用 Ram–Lak 滤波，并在均匀圆盘上做一次幅值标定。

调参协议。 网格（验证集 PSNR，NFE 50）：

- M1：60 视角 $\zeta \in \{3, 10, 30, 100, 300\} \times t_s \in \{0.1, 0.2, 0.3, 0.4, 0.5\}$；$I_0$=$10^5$ 时 $\zeta \in \{10, 30, 100\} \times t_s \in \{0.2, \ldots, 0.5\}$；
- M2：$\zeta \in \{0.5, 1, 2\}$（60 视角），$\zeta \in \{0.03, 0.05, 0.1, 0.25, 0.5, 1\}$（$I_0$=$10^5$）；
- M3：$\tilde{\lambda} \in \{0.01, 0.03, 0.1, 0.3, 1, 3\}$（60 视角），$\tilde{\lambda} \in \{1, 3, 10, 30, 100\}$（$I_0$=$10^5$）。

网格持续外扩，直到没有最优值落在边界上（共外扩两次）。60 视角选出的参数复用于 30 与 90 视角，I_0=10^5 选出的参数用于 I_0=10^4。选定值：M1 $(\zeta, t_s) = (30, 0.4)$（两种情形相同），M2 $\zeta = 1$（稀疏）/ 0.1（低剂量），M3 $\tilde{\lambda} = 0.3$（稀疏）/ 30（低剂量）。I_0=10^4 没有重新调参。

表 1: test200 上的单样本结果（NFE 50）。PSNR 单位 dB，括号内为按病人的 95% bootstrap 置信区间；SSIM 在重建圆内计算；DC $= \|\mathcal{A}(\hat{\boldsymbol{x}}) - \boldsymbol{y}\|/\|\boldsymbol{y}\|$。每个设置的最佳 PSNR 加粗。

设置	方法	PSNR↑ [95% CI]	SSIM↑	LPIPS↓	DC↓
30 视角	FBP	23.50 [22.62,24.31]	0.429	0.365	0.0616
	FBPConvNet（监督）	**32.22** [30.85,33.54]	0.824	0.116	0.0078
	M1 梯度引导	24.40 [23.62,25.07]	0.575	0.335	0.0382
	M2 ΠGDM 伪逆	32.17 [30.41,33.90]	0.804	0.140	0.0019
	M3 近端一致性	31.62 [29.76,33.31]	0.758	0.132	0.0015
60 视角	FBP	28.50 [27.49,29.37]	0.635	0.222	0.0399
	FBPConvNet（监督）	35.50 [33.83,36.98]	0.893	0.084	0.0050
	M1 梯度引导	24.54 [23.78,25.24]	0.585	0.334	0.0387
	M2 ΠGDM 伪逆	**36.93** [34.97,38.74]	0.899	0.109	0.0024
	M3 近端一致性	35.95 [33.65,38.28]	0.861	0.083	0.0011
90 视角	FBP	30.58 [29.66,31.48]	0.734	0.143	0.0358
	FBPConvNet（监督）	37.41 [35.63,39.03]	0.921	0.066	0.0045
	M1 梯度引导	24.54 [23.78,25.24]	0.585	0.334	0.0389
	M2 ΠGDM 伪逆	38.09 [35.97,39.91]	0.916	0.107	0.0032
	M3 近端一致性	**38.62** [35.94,41.11]	0.904	0.065	0.0010
低剂量 $I_0{=}10^5$	FBP	26.21 [25.31,26.96]	0.580	0.309	0.0360
	FBPConvNet（监督）	**35.32** [33.88,36.51]	0.888	0.088	0.0109
	M1 梯度引导	24.55 [23.81,25.25]	0.590	0.333	0.0393
	M2 ΠGDM 伪逆	33.16 [31.69,34.48]	0.837	0.122	0.0124
	M3 近端一致性	30.60 [29.34,31.88]	0.744	0.191	0.0089

指标。 重建圆内的 PSNR（动态范围 2，即 $[-1000, 1000]$ HU 窗）；在重建圆内平均的 SSIM（在恒定背景上计算会抬高所有方法）；LPIPS（AlexNet） [28]；测量一致性 $\|\mathcal{A}(\hat{\boldsymbol{x}}) - \boldsymbol{y}\|/\|\boldsymbol{y}\|$。对生成式方法还报告 K 个样本后验均值的 PSNR 与逐像素后验标准差的均值。由于 200 张测试切片来自 20 位病人，95% 置信区间与配对差都用按病人的聚类 bootstrap（2000 次重采样）计算。

算力。 全部实验在单张 RTX 5090（32 GB）上完成。先验在 `torch.compile` 与 channels-last 内存布局下为 0.19 s/步（共 6.3 h）；调参与后验采样 3.9 h，四个 FBPConvNet 共 1.8 h，合计约 12 GPU 小时。

5 结果

主要比较。 表 1 汇总了单样本结果。两种强制一致性的规则（M2、M3）在稀疏视角下比 FBP 高 7.4–8.7 dB。与按协议单独训练的监督基线相比，ΠGDM 在 30 视角持平（-0.06 dB，CI $[-0.69, 0.58]$），

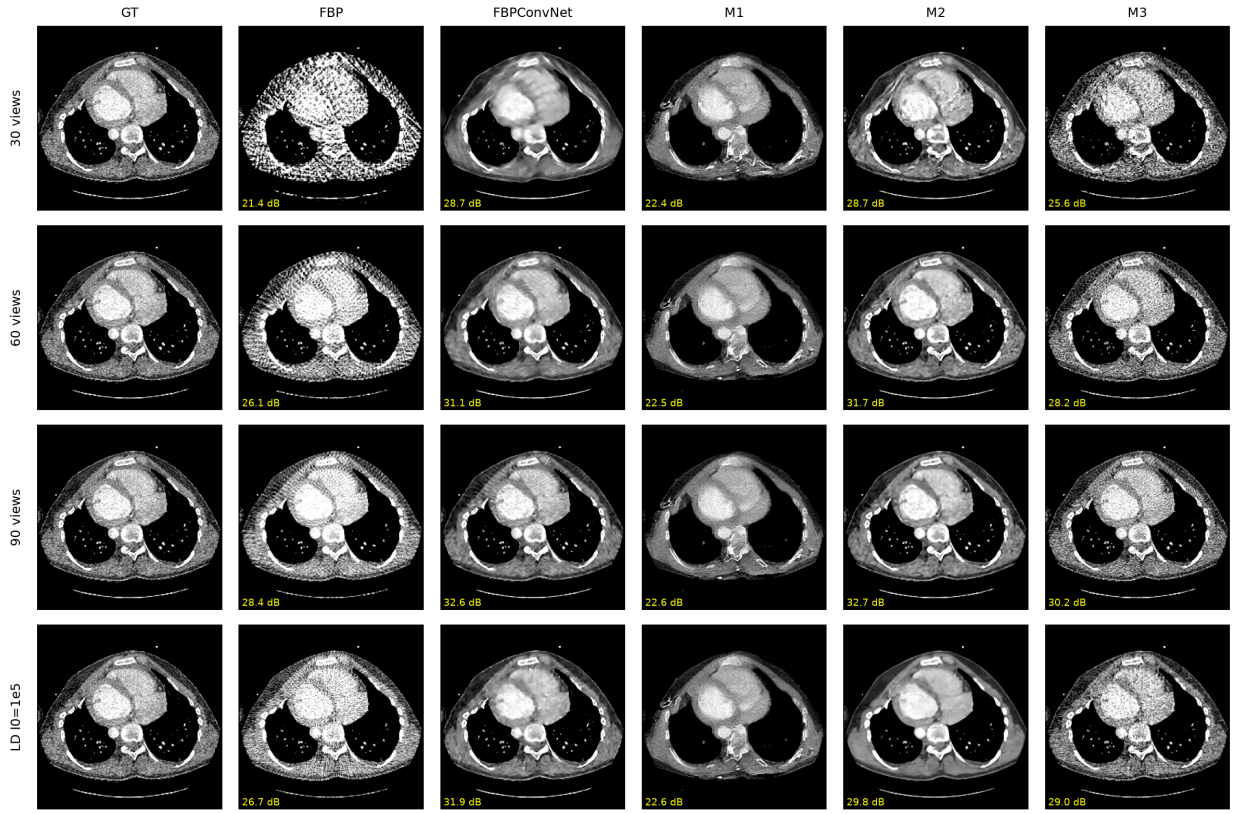


图 1: 一张胸部测试切片（软组织窗 W400/L40；重建圆外已遮掉）。数字为圆内 PSNR；这张临床扫描噪声较大，低于数据集平均水平（见表 1）。M1 改变了椎体与肋骨（幻觉）；FBPConvNet 过度平滑；M2 最锐利；M3 保留了测量扫描的噪声纹理。

在 60 视角更好（+1.43，$[0.95, 1.91]$），90 视角也更好（+0.68，$[0.30, 1.04]$）；近端一致性在 90 视角更好（+1.21，$[0.18, 2.35]$）。两种规则之间，ΠGDM 在 60 视角胜出（+0.97，$[0.35, 1.55]$），30 与 90 视角下差异不显著。二者的数据一致性残差为 0.10–0.32%，比 FBPConvNet（0.45–0.78%）低数倍。（表 1 中 M1 的 60 与 90 视角两行并非复制错误：逐图 PSNR 平均只差 0.0003 dB。）在图 1 的胸部切片上，FBPConvNet 过度平滑，30 视角下残留条纹；ΠGDM 最锐利；M3 保留了（本身含噪的）真值扫描的噪声纹理。

后验均值使排名反转。 对后验样本取平均（表 2）对所有方法都有帮助，但幅度不同：M3 提升 3.5 dB 并反超 M2，M2 提升 1.9 dB（后验均值上 M3−M2：60 视角 +0.82 $[0.28, 1.43]$，30 视角 +1.21 $[0.43, 2.04]$）。后验标准差图（图 2）提示了原因：M2 的不确定性小，集中在边缘和肺纹理；M3 的不确定性弥散、呈噪声状而非集中于边缘，这与” 样本主要在测量未约束的分量上不同、平均后相互抵消” 一致。与监督网络相比，M3 后验均值高 2.3–3.9 dB（30 视角 $[1.65, 3.02]$，60 视角 $[2.97, 4.95]$），M2 后验均值高 1.1–3.1 dB。因此，输出取单样本还是后验均值，决定了哪种规则更可取。

表 2: 单样本与 K 个样本后验均值的 PSNR（test200，NFE 50）以及逐像素后验标准差的均值。带置信区间的配对差见正文。

设置	方法	单样本	K 样本均值	标准差
60 视角，K=8	M1 梯度引导	24.53	26.22	0.129
	M2 ΠGDM 伪逆	36.75	38.60	0.053
	M3 近端一致性	35.95	**39.41**	0.060
30 视角，K=4	M1 梯度引导	24.50	25.86	0.123
	M2 ΠGDM 伪逆	31.45	33.33	0.067
	M3 近端一致性	31.63	**34.54**	0.066

步数效率。 图 3 在 60 视角下改变 NFE。M3 在 20 步时已达 36.2 dB（200 张切片 36 秒），步数增加后反而略有下降（100 步时 35.7 dB），这与”硬投影被更频繁地施加在含噪中间估计上”相符。M2 随步数增加而提升（34.3→37.4 dB），100 步时最好；M1 提升最多（19.1→28.1 dB），但即使 100 步仍低于 FBP。

梯度引导为何在流 ODE 上失效。 在一次初步测量中（4 张验证切片，60 视角，4 万步中间权重，NFE 20），M1 引导梯度的均方根在 t=0 时约为 1.9，而 $t \geq 0.2$ 时只有 0.03–0.07，下降约 60 倍，我们将其归因于纯噪声处网络雅可比很大；用最终权重的测量留待下一版。因此单一的 ζ 要么在第一步就把样本推离数据流形，要么在之后太弱：t_s=0 时最好的验证 PSNR 只有 13.8 dB（16 张，NFE 20），必须把引导推迟到 t_s=0.2–0.4（图 4）。即便调过参，M1 在 30、60、90 视角下都饱和在约 24.5 dB（表 1）。使用残差 范数的梯度时，步长不随 $\|\boldsymbol{r}\|$ 缩放，因而无法随一致性改善而减小；我们推测正是这一点加上恒定的 ζ（而非 ODE 本身）造成了与视角数无关的平台。随时间变化的引导权重 [13] 是自然的改进方向，留待后续工作。其样本只达到粗略一致（DC 约 3.8%，与 FBP 相当，是 M2/M3 的十倍以上），并会产生解剖结构幻觉（图 1、图 2）。修正项随残差消失的 M2 与 M3 没有这种表现。

低剂量。 存在 Poisson 噪声时情况不同。I_0=10^5 时监督的 FBPConvNet 最好（35.3 dB），比 M2 高 2.2 dB（CI $[1.86, 2.49]$），比 M3 高 4.7 dB；M3 需要很强的近端权重（$\tilde{\lambda}$=30）才不会把噪声带进图像。在光子饥饿的 I_0=10^4 下，直接沿用 I_0=10^5 的强度、不重新调参，排名倒转：FBP 18.0、M3 20.6、M2 22.5、M1 24.5 dB。M1 最稳健，可能正是因为它对数据利用最少。我们有意没有给 M2 和 M3 噪声模型（σ_y=0，无加权最小二乘），这在 Poisson 噪声下对它们不利，而 FBPConvNet 会隐式地学到噪声统计；重新调参或引入噪声模型能否弥补差距，仍是开放问题。

敏感性。 M3 最容易部署：在 $\tilde{\lambda} \in [0.01, 1]$ 范围内，验证 PSNR 变化不到 0.1 dB（图 4）；在无噪设置下它实际上相当于硬投影。M2 有明确的稳定性上限（稀疏视角下 ζ=2 即发散），M1 则需要二维搜索。

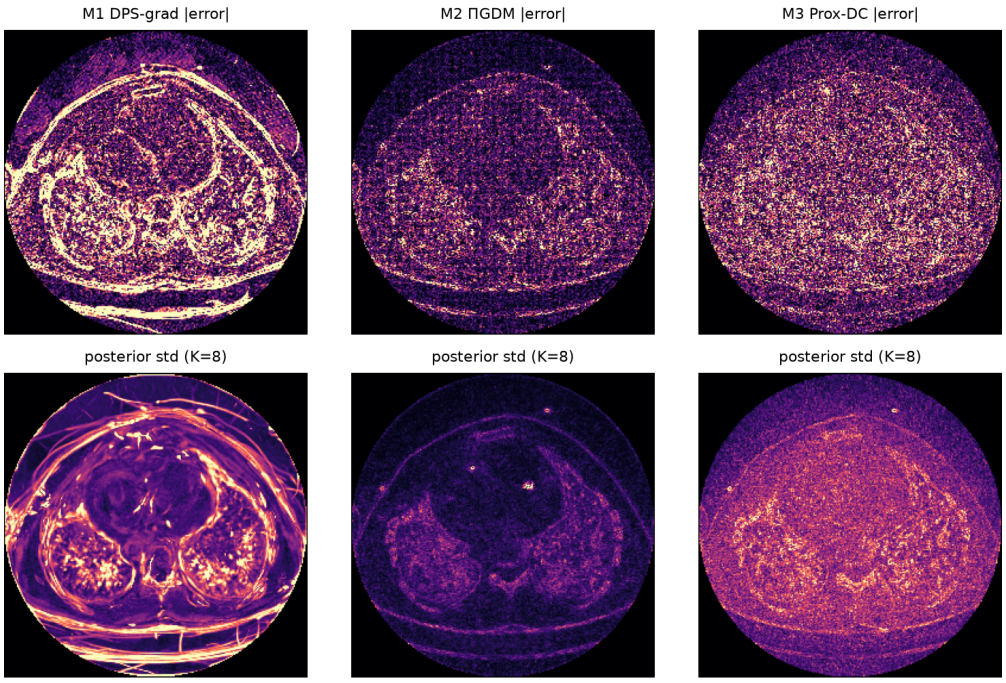


图 2: 单个样本的绝对误差（上）与 8 个样本的后验标准差（下），60 视角，与图 1 为同一切片。M1 的误差与不确定性沿解剖结构分布（它生成了不同的结构）；M2 的不确定性小且集中在边缘；M3 的不确定性呈噪声状。

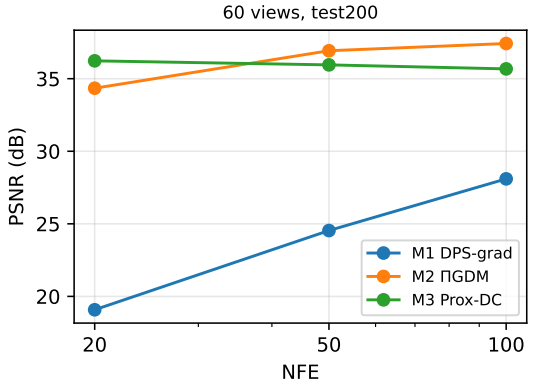


图 3: 60 视角下 PSNR 随 NFE 的变化（test200），引导强度固定为 NFE 50 时选定的值。得益于 Δt 缩放，积分后的总引导量在各 NFE 下相同。

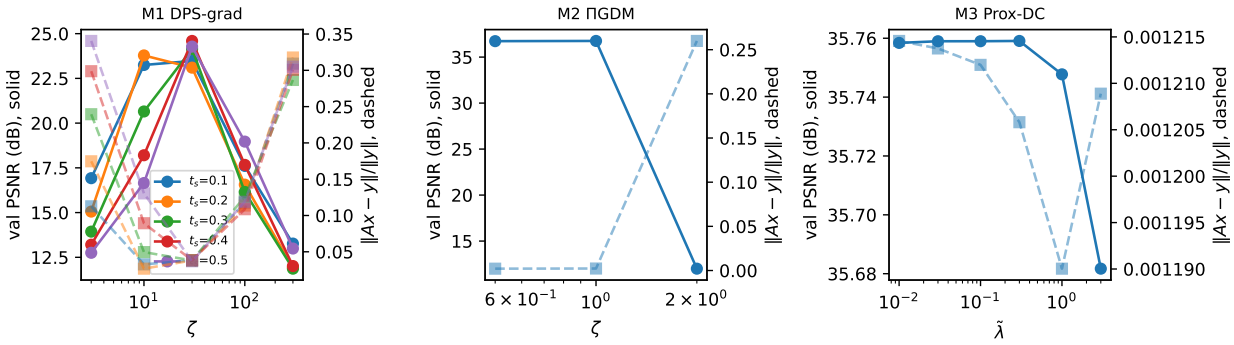


图 4: 60 视角下验证 PSNR（实线）与数据一致性（虚线）随引导强度的变化。M1：每个起始时刻 t_s 一条曲线；M2 在 ζ=2 时发散；M3 在两个数量级的 $\tilde{\lambda}$ 范围内都不敏感。

6 讨论与局限

对于无噪稀疏视角 CT 中的流匹配先验，本文结果支持修正项随残差消失的规则：中等 NFE 下单样本最好的是伪逆引导，少步采样和后验均值最好的是近端一致性。从扩散 SDE 移植过来、使用单位范数步长的梯度引导，即使调好单位和起始时刻，在 ODE 上也没有竞争力。存在光子噪声时，两种一致性规则都需要显式噪声模型或按剂量调参，才能赶上监督网络。

本研究有明确的局限。前向模型是作用在重建体数据上的仿真平行束投影，因此算子完全已知，训练与测试一致；扇束 / 锥束几何、算子失配以及真实投影数据（如 Mayo LDCT）都没有涉及。真值体数据本身包含含噪的临床扫描，这限制了可达到的 PSNR，也会惩罚去噪行为。引导强度对每种噪声情形只调一次，再迁移到不同视角数和剂量，这对最优值容易迁移的规则有利；我们把这视为测量内容的一部分。监督基线的样本遍历数约为先验的 1/25，因此其数字是下界。先验是二维的，不保证层间一致性 [22, 23]；M1 的轨迹分析使用的是中间权重；后验均值结果只用了 K=8（60 视角）和 K=4（30 视角）个样本。

代码与数据

代码、配置文件、逐图指标以及各划分的病人列表公开于 `https://github.com/ZeroDevi1/flow-ct-guidance`。数据为公开的 TotalSegmentator v2.0.1（CC-BY-4.0）。

致谢

本文的实验代码、实验执行与论文初稿借助了 AI 编程助手（Claude，Anthropic）完成。全部结果与文字均经作者核查，作者对内容负全部责任。

参考文献

[1] Yang Song, Liyue Shen, Lei Xing, and Stefano Ermon. Solving inverse problems in medical imaging with score-based generative models. In *International Conference on Learning Representations (ICLR)*, 2022.

[2] Hyungjin Chung, Byeongsu Sim, Dohoon Ryu, and Jong Chul Ye. Improving diffusion models for inverse problems using manifold constraints. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.

[3] Hyungjin Chung, Jeongsol Kim, Michael T. Mccann, Marc L. Klasky, and Jong Chul Ye. Diffusion posterior sampling for general noisy inverse problems. In *International Conference on Learning Representations (ICLR)*, 2023.

[4] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. In *International Conference on Learning Representations (ICLR)*, 2023.

[5] Xingchao Liu, Chengyue Gong, and Qiang Liu. Flow straight and fast: Learning to generate and transfer data with rectified flow. In *International Conference on Learning Representations (ICLR)*, 2023.

[6] Davide Evangelista. Physics-guided flow matching for CT image reconstruction, 2026. arXiv:2608.28256.

[7] Jiayang Shi, Daniel M. Pelt, and K. Joost Batenburg. DM4CT: Benchmarking diffusion models for computed tomography reconstruction, 2026. arXiv:2602.18589.

[8] Jiayang Shi, Lincen Yang, Zhong Li, Tristan van Leeuwen, Daniel M. Pelt, and K. Joost Batenburg. Efficient flow matching for sparse-view CT reconstruction, 2026. arXiv:2603.00205.

[9] Jigang Duan, Jiayi Wang, Heran Wang, Ping Yang, Genwei Ma, and Xing Zhao. LUCID: Learned undersampling-adaptive consistency-guided inference with deterministic flow matching for sparse-view CT reconstruction, 2026. arXiv:2606.16212.

[10] Ashwini Pokle, Matthew J. Muckley, Ricky T. Q. Chen, and Brian Karrer. Training-free linear image inverses via flows. *Transactions on Machine Learning Research*, 2024.

[11] Ségolène Martin, Anne Gagneux, Paul Hagemann, and Gabriele Steidl. PnP-Flow: Plug-and-play image restoration with flow matching. In *International Conference on Learning Representations (ICLR)*, 2025.

[12] Jeongsol Kim, Bryan Sangwoo Kim, and Jong Chul Ye. FlowDPS: Flow-driven posterior sampling for inverse problems. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2025.

[13] Liam Moroy, Jean-François Giovannelli, Yoann Altmann, Steve McLaughlin, Frédéric Champagnat, and Guillaume Bourmaud. Getting your guidance weights right in diffusion and flow-matching posterior sampling, 2026. arXiv:2610.03503.

[14] Aneesh Barthakur, Mathias Niepert, and Luiz F. O. Chamon. Learned end-to-end guidance schedules for diffusion models, 2026. arXiv:2610.01502.

[15] Jakob Wasserthal, Hanns-Christian Breit, Manfred T. Meyer, Maurice Pradella, Daniel Hinck, Alexander W. Sauter, Tobias Heye, Daniel T. Boll, Joshy Cyriac, Shan Yang, Michael Bach, and Martin Segeroth. TotalSegmentator: Robust segmentation of 104 anatomic structures in CT images. *Radiology: Artificial Intelligence*, 5(5):e230024, 2023. doi: 10.1148/ryai.230024.

[16] Jiaming Song, Arash Vahdat, Morteza Mardani, and Jan Kautz. Pseudoinverse-guided diffusion models for inverse problems. In *International Conference on Learning Representations (ICLR)*, 2023. URL `https://openreview.net/forum?id=9_gsMA8MRKQ`.

[17] Hyungjin Chung, Suhyeon Lee, and Jong Chul Ye. Decomposed diffusion sampler for accelerating large-scale inverse problems. In *International Conference on Learning Representations (ICLR)*, 2024.

[18] Kyong Hwan Jin, Michael T. McCann, Emmanuel Froustey, and Michael Unser. Deep convolutional neural network for inverse problems in imaging. *IEEE Transactions on Image Processing*, 26(9):4509–4522, 2017. doi: 10.1109/TIP.2017.2713099.

[19] Yuanzhi Zhu, Kai Zhang, Jingyun Liang, Jiezhang Cao, Bihan Wen, Radu Timofte, and Luc Van Gool. Denoising diffusion models for plug-and-play image restoration. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2023.

[20] Bingliang Zhang, Wenda Chu, Julius Berner, Chenlin Meng, Anima Anandkumar, and Yang Song. Improving diffusion inverse problem solving with decoupled noise annealing. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2025. doi: 10.1109/CVPR52734.2025.01946.

[21] Morteza Mardani, Jiaming Song, Jan Kautz, and Arash Vahdat. A variational perspective on solving inverse problems with diffusion models. In *International Conference on Learning Representations (ICLR)*, 2024.

[22] Hyungjin Chung, Dohoon Ryu, Michael T. McCann, Marc L. Klasky, and Jong Chul Ye. Solving 3d inverse problems using pre-trained 2d diffusion models. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 22542–22551, 2023. doi: 10.1109/CVPR52729.2023.02159.

[23] Bowen Song, Jason Hu, Zhaoxu Luo, Jeffrey A. Fessler, and Liyue Shen. DiffusionBlend: Learning 3D image prior through position-aware diffusion score blending for 3D computed tomography reconstruction, 2024. arXiv:2406.10211.

[24] Jiaming Liu, Rushil Anirudh, Jayaraman J. Thiagarajan, Stewart He, K. Aditya Mohan, Ulugbek S. Kamilov, and Hyojin Kim. DOLCE: A model-based probabilistic diffusion framework for limited-angle CT reconstruction. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023.

[25] Junseo Bang, Dong Ju Mun, Hoigi Seo, Seongmin Hong, and Se Young Chun. Triadic dynamics aware diffusion posterior sampling for inverse problems: Optimizing guidance and stochasticity schedules, 2026. arXiv:2605.26470.

[26] Hu Chen, Yi Zhang, Yunjin Chen, Junfeng Zhang, Weihua Zhang, Huaiqiang Sun, Yang Lv, Peixi Liao, Jiliu Zhou, and Ge Wang. LEARN: Learned experts' assessment-based reconstruction network for sparse-data CT. *IEEE Transactions on Medical Imaging*, 37(6):1333–1347, 2018. doi: 10.1109/TMI.2018.2805692.

[27] Patrick Esser, Sumith Kulal, Andreas Blattmann, Rahim Entezari, Jonas Müller, Harry Saini, Yam Levi, Dominik Lorenz, Axel Sauer, Frederic Boesel, Dustin Podell, Tim Dockhorn, Zion English, Kyle Lacey, Alex Goodwin, Yannik Marek, and Robin Rombach. Scaling rectified flow transformers for high-resolution image synthesis. In *International Conference on Machine Learning (ICML)*, 2024.

[28] Richard Zhang, Phillip Isola, Alexei A. Efros, Eli Shechtman, and Oliver Wang. The unreasonable effectiveness of deep features as a perceptual metric. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018.